

# Low-rate DDoS attack detection method using data compression and behavior divergence measurement (LDDM)

Jan 2021

Computer and Security

14 citations

حملات منع خدمت توزیع شده به دو دسته high-rate و low-rate تقسیم می‌شوند. حملات منع خدمت با نرخ پایین (مخفی) به دلیل شباهتشان با ترافیک‌های معمولی به سختی قابل شناسایی هستند. این مقاله اسکچ‌های چندبعدی<sup>۱</sup> و روشهای اندازه گیری بهینه برای جریانهای شبکه ارایه می‌دهد. متود اندازه گیری واگرایی<sup>۲</sup> بهبود یافته که بر اساس daub4 wavelet transform می‌باشد، درصد انرژی واگرایی هر اسکچ را اندازه گیری می‌کند. که استفاده از این روش منجر به دستیابی به نتایج خوبی در تمایز ترافیک معمولی و مهاجم می‌شود. علاوه بر این یک روش میانگین متحرک نمایی وزنی اصلاح شده<sup>۳</sup> که برای ساخت آستانه ترافیک نرمال می‌باشد، طراحی شده است. در همین حال یک مکانیزم فریز ترافیک برای اطمینان از استاندارد بودن آستانه متغیر ارایه شده است. در آخر نیز نرخ مثبت/منفی کاذب آن را با متودهای دیگر بررسی می‌کنیم و مشاهده می‌شود که دقت بالایی در شناسایی حملات مخفیانه نرخ پایین دارد.

روشهای بسیاری از انواع مختلف برای شناسایی حملات منع خدمت توزیع شده ارایه شده است: مبتنی بر مدل احتمالاتی، نظریه اطلاعات، اندازه گیری فاصله، یادگیری ماشین، پردازش سیگنال (روش‌های مبتنی بر سیگنال حساسیت بیشتری نسبت به تغییرات دارند).

LDDOS ها تفاوت کمی در حجم و feature ها با ترافیکهای نرمال و معمولی دارند. Daub4 wavelet transform که یک نوع متداول از discrete wavelet transform می‌باشد نسبت به تغییرات سیگنالی جزئی حساس است. همچنین ما از اسکچهای چند بعدی برای ذخیره اطلاعات جریان که از توابع هش تصادفی استفاده می‌کنند، به جای روش‌های نمونه برداری<sup>۴</sup> استفاده می‌کنیم. به دلیل یکتا بودن مقصد جریان‌ها، جریان‌ها تنها روی آپی مبدا خلاصه می‌شدند. اما در اینجا جریان‌های دوطرفه را در نظر می‌گیرد. به جای اندازه گیری ساختارهای اسکچ بازه زمانی واحد، واگرایی‌های اسکچ در بازه‌های زمانی<sup>۵</sup> بازبینی و دوباره اندازه گیری شده‌اند. برای نشان دادن واگرایی اسکچ، baseline شبکه مورد نیاز است. بنابراین برای اندازه گیری baseline شبکه به صورت دقیق و بلادرنگ<sup>۶</sup>، متود حد آستانه پویا با استفاده از روش میانگین متحرک نمایی استفاده شده است. همچنین برای جلوگیری از اثرگذاری ترافیک مهاجم بر روی baseline، مکانیزم فریز برای استاندارد سازی آن استفاده می‌شود.

<sup>1</sup> multi dimensional

<sup>2</sup> divergence

<sup>3</sup> Modified weighted exponential moving average

<sup>4</sup> sampling

<sup>5</sup> Time interval

<sup>6</sup> Real-time

## چند تعریف:

**اسکچ:** به دلیل ماهیت تصادفی بودن توابع هش، توزیع ترافیک نرمال در هر جدول هش تقریباً تصادفی است. و لذا زمانی که ترافیک شبکه به صورت محسوسی تغییر کند، توزیع هش نیز به صورت عظیمی تغییر می‌کند تا آنومالی‌ها را نشان دهد.

**wavelet: Daub 4 wavelet transform** ها با توجه به ویژگی‌ای که دارند می‌توانند تغییرات ناخواسته، حتی جزئی‌ترین‌ها را نیز تشخیص دهند. یک سیگنال  $S$  که از  $K$  تا المان تشکیل شده است، به یک سیگنال  $A$  و یک سیگنال جزئی  $D$  با استفاده از تبدیل تجزیه می‌شود. و بر اساس این دو سیگنال درصد انرژی سیگنال  $S$  اندازه‌گیری می‌شود ( $P^d$ ) تا تغییرات سیگنال را نشان دهد.

این متود دو مجموعه ضریب از پیش تعریف شده دارد: ضریب‌های مقیاسی  $\{\alpha_1, \alpha_2, \alpha_3, \alpha_4\}$  و ضریب‌های موجک  $\{\beta_1, \beta_2, \beta_3, \beta_4\}$  که اینها باید در یک رابطه برقرار باشند. سیگنال مقیاسی  $duab\ 4$  یک ماتریس  $2/K * K$  می‌باشد:

$$V = \begin{pmatrix} \alpha_1 & \alpha_2 & \alpha_3 & \alpha_4 & 0 & 0 & \dots & 0 & 0 \\ 0 & 0 & \alpha_1 & \alpha_2 & \alpha_3 & \alpha_4 & \dots & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ \alpha_3 & \alpha_4 & 0 & 0 & 0 & 0 & \dots & \alpha_1 & \alpha_2 \end{pmatrix}$$

سیگنال موجکی  $W$  نیز با همان ابعاد می‌باشد و به همان صورت و تنها با جاگزینی ضرایب موجکی ارایه می‌شود. و به نحو زیر انرژی سیگنال  $S$  محاسبه می‌شود:

$$\begin{aligned} a_i &= \sum_{j=1}^K S_j V_{ij} \quad i \in \{1, 2, \dots, \frac{K}{2}\}, & A_j &= \sum_{i=1}^{\frac{K}{2}} a_i V_{ij} \quad j \in \{1, 2, \dots, K\}, \\ d_i &= \sum_{j=1}^K S_j W_{ij} \quad i \in \{1, 2, \dots, \frac{K}{2}\}, & D_j &= \sum_{i=1}^{\frac{K}{2}} d_i W_{ij} \quad j \in \{1, 2, \dots, K\}. \end{aligned} \quad \Rightarrow \quad P^d(S) = \frac{\sum_{j=1}^K (D_j)^2}{(\sum_{j=1}^K (A_j)^2 + \sum_{j=1}^K (D_j)^2)}$$

$P^d$  زمانی که ترافیک شبکه در حالت غیرعادی باشد به سرعت تغییر می‌کند و مقدارش افزایش پیدا می‌کند اما در حالت عادی مقدار بسیار پایینی خواهد داشت.

## معماری LDDM:

از سه تا کامپوننت تشکیل شده است:




Figure.2 Framework of the proposed low-rate DDoS attacks detection method

**Sketch**: در ابتدا ترافیک شبکه در همه بازه‌ها به صورت جریانی جمع شده و سپس آنها را به پروسه تشخیص ارسال می‌کند. در اسکچ، جریانه‌ها در یک ساختار اسکچی با کلیدهای آپی مبدا و مقصد  $\langle SIP, DIP \rangle$  نگاشت شده‌اند. سپس واگرایی بین اسکچ بازه فعلی و بازه نرمال قبلی حساب شده است (behavior divergence method based on daub 4 wavelet transform) تا  $p^d$  را که برای کامپوننت تشخیص می‌باشد، فراهم کند.

## Daub4 wavelet transform:

ابتدا چند تعریف ارائه می‌دهیم:

**Abnormal hash table**: جدول هش ای که انحراف سیگنالی آن در محدوده آستانه نباشد.

**Abnormal sketch**: اسکچی که بیش از  $H/2$  توابع هش آن abnormal باشند.

**Abnormal time**: یک بازه زمانی است که در آن یک abnormal sketch در ساختار multi-dimensional sketch باشد. اگر یک بازه زمانی این گونه باشد، مدل مان یک هشدار<sup>8</sup> می‌فرستد.

هر جدول اسکچ به صورت یک سیگنال در نظر گرفته می‌شود و واگرایی بین دو سیگنال متوالی که توزیع خوبی دارند- ترافیک عادی هستند- مقدار واگرایی پایین می‌باشد. برای اندازه‌گیری این واگرایی، این مقاله از daub4 استفاده می‌کند. با اندازه‌گیری درصد انرژی واگرایی سیگنال، برزگی واگرایی<sup>9</sup> را به دست می‌آورد.

<sup>8</sup> alarm

<sup>9</sup> Divergence magnitude

---

**Algorithm 1.** The improved behavior divergence measurement method based on daub 4 wavelet transform

---

Input: the sketches of the  $t^{\text{th}}$  time interval, the sketches of the  $t+1^{\text{th}}$  time interval

Output: the  $P^d$  set

- (1) Initialize  $P^d\_set = \emptyset$
  - (2) For each sketch in multidimensional sketch
  - (3)  $PD = \emptyset$
  - (4) For each row  $S_i$  in a sketch
  - (5)  $S_{dev} = |S_{t+1,i} - S_{t,i}|$
  - (6) Sort  $S_{dev}$  ascendingly
  - (7) Calculate  $P^d_i$  of  $S_{dev}$
  - (8) Add  $P^d_i$  to  $PD$
  - (9) End for
  - (10) Add  $PD$  to  $P^d\_set$
  - (11) End for
- 

همانگونه که دیده می شود این روش بدون نیاز به دیتاست های آموزشی روش های مبتنی بر یادگیری ماشین، **با ترافیک و رفتار متغیر**

**پدیت می شود.**

**Dynamic threshold:** روش ما چون می خواهد با ترافیک دائماً در حال تغییر سازگار باشد، باید پویا باشد. به دلیل خاصیت پویایی ذاتی شبکه، درصد انرژی واگرایی سیگنال ثابت نمی باشد. و ثابت بودن این مقدار می تواند باعث نرخ مثبت و منفی کاذب زیادی شود. از روش میانگین متحرک متحرک نمایی بهبود یافته (IEWMA) برای محاسبه آستانه پویا استفاده می شود.

پارامتهایی که کلاه دارند مقدار تخمینی و بقیه مقادیر واقعی می باشند. آلفا بتا و لاندا پارامترهای تغییر پذیر می باشند. به دلیل این که در حملات منع خدمت توزیع شده آدرسهای IP مبدا توزیع شده می باشند لذا انرژی اسکچ ( $p^d(s)$ ) کم خواهد بود اما در IP های مقصد مقادیر بالا می روند. لذا آستانه های پویا این دو باید روش های متفاوتی باشد:

$$\begin{aligned} \hat{p}_{t+1}^d &= \alpha p_t^d + (1 - \alpha) \hat{p}_t^d, & \text{Src IP role:} & \delta_{t+1} = \begin{cases} 1 & Th_{t+1} > p_{t+1}^d \\ 0 & Th_{t+1} < p_{t+1}^d \end{cases} \\ d_t &= |p_t^d - \hat{p}_t^d|, \\ \sigma_{t+1}^2 &= \beta d_t^2 + (1 - \beta) \sigma_t^2, & \Rightarrow & \\ Th_{t+1} &= \begin{cases} \hat{p}_{t+1}^d + \lambda \sigma_{t+1} \text{ sketch.attribute} = DIP \\ \hat{p}_{t+1}^d - \lambda \sigma_{t+1} \text{ sketch.attribute} = SIP' \end{cases} & \text{Dst IP role:} & \delta_{t+1} = \begin{cases} 1 & Th_{t+1} < p_{t+1}^d \\ 0 & Th_{t+1} > p_{t+1}^d \end{cases} \end{aligned}$$

اگر انرژی از مقادیر آستانه بیشتر شود، یعنی یک abnormal hash table می باشد. و علاوه بر این برای جلوگیری از استفاده این مقدار انرژی در بازه بعد ( که منجر به نرخ منفی کاذب میشود) از مکانیزم فریز برای آستانه و سیگنال استفاده می شود. تا زمانی که حمله برطرف شود، به روزرسانی آستانه ادامه می یابد.

a destination IP address as an example to describe the implementation of freezing mechanism.

---

**Algorithm 2.** Freezing Mechanism

---

Input:  $P_t^d$  of the  $t^{\text{th}}$  time interval,  $Th_t$  of the  $t^{\text{th}}$  time interval,  $\sigma, \beta, \lambda$

Output:  $Th_{t+1}$

- (1) If  $P_t^d > Th_t$
  - (2) freeze  $S_{t,i}, Th_t$
  - (3) While  $P_{t+1}^d < Th_t$
  - (4) calculate the  $P^d$  value of the next time interval  $P_{t+1}^d = P^d(S_{t+1,i}, S_{t-1,i})$ , continue to compare  $P_{t+1}^d$  and  $Th_t$
  - (5) End while
  - (6) Else
  - (7) calculate the  $P_{t+1}^d$  and  $Th_{t+1}$  value of the next time interval, continue to compare  $Th_{t+1}$  and  $P_{t+1}^d$
  - (8) End if
  - (9) unfreeze  $Th$ , calculate the  $Th_{t+1}$  value of the next time interval and  $P_{t+1}^d = P^d(S_{t+1,i}, S_{t,i})$ , compare  $P_{t+1}^d$  and  $Th_{t+1}$
- 

در کامپوننت آستانه پویا، طبق مجموعه  $p^d$  روش میانگین متحرک وزنی نمایی سازگار استفاده می شود تا آستانه تشخیص  $Th$  را تقریب بزند. ورودی  $p^d$  با  $Th$  مقایسه می شود. سپس  $p^d$  در مجموعه  $p^d$  ذخیره می شود.

اگر تشخیص داده شد که حمله ای رخ داده است مکانیزم فریز صدا زده می شود تا اسکچ، آستانه ها و متغیرهای مورد استفاده برای تخمین آستانه پویا را فریز کند.

## تنظیم پارامترها:

H,K : علاوه بر خطا و آزمایش نظریه های مختلفی برای اثبات برقراری storage accuracy نیز موجود می باشد.

آلفا، بتا و لاندا : ضرایب میرایی هستند که می توانند میزان وابستگی مقدار آستانه به مقادیر بازه های قبلی را تعیین کنند. تاثیر لاندا بیشتر می باشد و بایستی با دقت بیشتری تعیین شود.

بازه زمانی<sup>۱۰</sup> تشخیص دلتا: ریزدانی تشخیص و زمان بازخورد را تعیین می:ند. ریزدانی تشخیص پایین نمی تواند مشخصه های آماری ترافیک را نشان دهد و می تواند به نرخ مثبت کاذب بالا منجر شود. همچنین در زمان پاسخ نیز مساله دارد. ریزدانی های بالا اطلاعات آماری حملات LDDOS را در حجم بزرگی از ترافیک نمی توانند بازتاب دهند که منجر به نرخ منفی کاذب بالایی می شود. در این مقاله طول بازه ۱۰ ثانیه تنظیم شده است.

مقادیر اولیه اسکچ و آستانه ها بر اساس ترافیک نرمال اولیه شبکه تا زمان  $m$ ، به دست می آیند. این فرض بلاشکال و طبیعی است که در شبکه ی ما تا آن زمان، ترافیک ها نرمال هستند. در اینجا ما  $m$  را ۱۰ گرفتیم.

---

<sup>10</sup> Time interval

**ارزیابی:** ترافیک های نرمالی که ضبط شده به همراه ترافیک های حملات منع خدمتی که در آزمایشگاه خودمان اجرا کرده ایم با نسبت های مختلفی تشکیل انواع دیتاست ها را می دهند. معیارهای بررسی موثر بودن LDM شامل Accuracy,TPR,FPR,FNR می باشند.

### پیش پردازش داده ها:

- ضبط بسته ها با استفاده از وایرشارک و به دست آوردن مقادیر: timestamp,srcIP,destIP,src port,dest .port,protocol and bytes
- تبدیل آدرسهای آیپی به مقادیر عددی
- تجمیع ها بسته ها در جریانها با مشخصات srcIP,dstIP در مدت زمان بازه زمانی تعیین شده.

نتایج نهایی بدین شرح می باشد:

Items	Parameters	Description	Values of Dataset1,2,3	Values of Dataset4	Values of Dataset5
Sketch	$H$	Number of hash functions	5	5	5
	$K$	Size of hash table	100	100	16000
	$\alpha$	Damping coefficient	0.1	0.7	0.7
IEWMA	$\beta$	Variance damping coefficient	0.1	0.1	0.3
	$\lambda$	Threshold damping coefficient	3	3	4
Other parameters	$\Delta T$	Detection time interval	20s	20s	20s

Dataset	Dataset1	Dataset2	Dataset3	Dataset4	Dataset5
Acc	0.97	0.98	0.98	0.98	0.95
TPR	0.95	1	1	1	1
FPR	0.01	0.02	0.02	0.02	0.05
FNR	0.04	0	0	0	0

C. Availability analysis of multidimensional sketch structure

همچنین در بحث بررسی اسکچها مشاهده می کنیم که اسکچهای تک بعدی (مثلا کلید آنها تنها SIP می باشد) در مقایسه با اسکچ های چندبعدی استفاده شده دقت پایین تری خواهند داشت. به دلیل این است که در زمان وقوع حملات منع خدمت توزیع شده، مجموعه آدرس آیپی مبدا و مقصد بهتر می تواند بی نظمی را نشان بدهند.

سپس کارایی متود اندازه گیری واگرایی بهبود یافته مبتنی بر daub4 (reordered duab4) (میزان بزرگ بودن انرژی  $p^d$ ) با قبل از بهبود آن مقایسه شده است که نتیجه می گیریم بهتر می تواند در تشخیص ترافیک حمله کمک کند. (یعنی در صورت وقوع حمله  $p^d$  بزرگتر می باشد)

برای ارزیابی روش بکاررفته برای آستانه پویا و مکانیزم فریز، مشاهده می شود که این راهکار ها به خوبی در ترافیک دایم در حال تغییر جواب می دهند.

در کارهای آینده برای بررسی زمان موردنیاز، به برروی تکنیک نمونه برداری و توزیع یافتگی برای کاهش بیشتر پردازش جریان های شبکه در شبکه های با سرعت بالا بررسی می کنیم

در آخر راهکارمان را با چندتا روش دیگر که آنها هم از اسکچ ها و روشهای سیگنالی استفاده می کنند بررسی می نماییم. نتیجه می شود که واگرایی اسکچ در بازه های زمانی متوالی بهتر میتواند از اسکچ های تنها در یک بازه زمانی واحد حملات را تشخیص دهد. تبدیل

موجب نیز به در مقایسه با دیگر متودها حساستر است. در خلاصه که IDDM به خوبی می تواند LDDOS ها را در محیط های مختلف شبکه (LAN یا WAN) شناسایی کند.

## نتیجه گیری: