

Smart Defense: A distributed deep defense against DDoS attacks with edge computing

Arizona State University

2022

Computer Networks

ظهور دستگاه‌های IOT منجر به بروز حملات منع خدمت با ترافیک حجیم (تا ۲.۳ ترابایت بر ثانیه) شده است. روشهای پیشگیری شناسایی حملات منع خدمت به دو دسته تقسیم می‌شوند:

- نزدیک مقصد: استفاده از همان روش‌های سنتی یادگیری ماشین و پکت فیلترینگ و کنترل نرخ گذر و..... این روش‌ها به دلیل شبیه بودن ترافیک کاذب با ترافیک‌های نرمال مثبت کاذب زیادی دارند. و در مقابل حملات حجیم امروزی تنها راه‌حلی که باقی می‌گذارند، قطع سیستم قربانی و یا هدایت ترافیک به مراکز دیگری است.
- نزدیک مبدا: در ترافیک‌های حجیم و توزیع شده امروزی کافی نیستند به دلیل این که اطلاعات کافی از استریم‌ها ندارند و نمی‌توانند حملات توزیع شده را به درستی تشخیص دهند.

روشهای شناسایی از جهتی دیگر به دو دسته تقسیم می‌شوند اما در حجم‌های حملات امروزی با مشکل روبرو خواهند شد:

- آماری
- یادگیری ماشین

شبکه‌های نرم‌افزارمحور برای مدیریت شبکه‌هایی شامل اینترنت اشیا استفاده می‌شوند و مدیریت شبکه‌های با گستردگی بالا را آسان‌تر می‌کنند. همچنین راهکارهای ایمن نگهداشتن مبتنی بر این شبکه‌ها ارائه شده است.

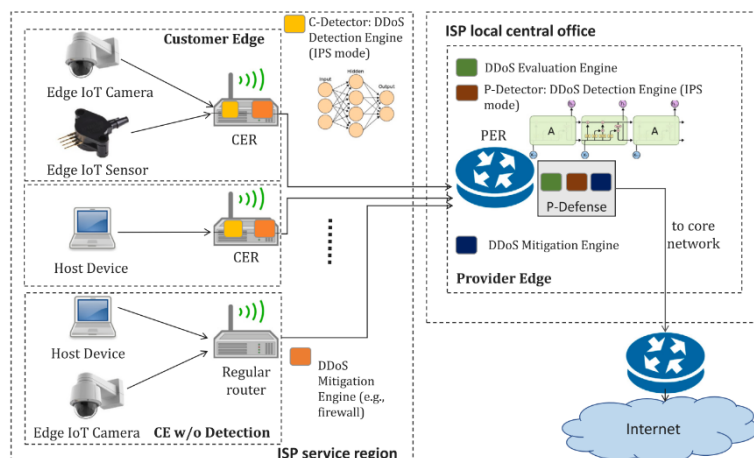
روشهای مبتنی بر یادگیری عمیق با وجود موثر واقع شدن در مقابله با حجیم بودن ترافیک یا از روشهای مبتنی بر یادگیری ماشین استفاده می‌کنند مانند Self organizing Map که در بحث یادگیری با کندی یا نرخ مثبت کاذب بالا در ترافیک‌های بلادرنگ مواجه هستند یا منجر به خطای مثبت کاذب در real-time می‌شوند. روشهای مبتنی بر یادگیری تقویتی عمیق با وجود عملکرد خوب در شناسایی و ذخیره کردن الگوهای ترافیک، یافتن راه حل بهینه (الگوی حمله) ناکارآمد بوده و می‌توانند یکنواختی را نقض و تاخیر ایجاد کنند. روشی که ارائه می‌دهیم به ISP ها این امکان کنترل را می‌دهد که مدل آموزش داده شده با حملات در حال تغییر سازگار باشد. همچنین این دسته از روش‌های یادگیری ماشین امکان پیاده سازی روی سخت‌افزارهای محدود را دارا می‌باشند.

این مقاله قصد دارد یک روش توزیع شده مبتنی بر تشخیص بی‌نظمی یادگیری ماشین برای شناسایی و مقابله با حملات منع خدمت توزیع شده با کمک محاسبات لبه ارائه دهد. این روش به دلیل شناسایی مقدار زیادی از حملات در مبدا (معیار کارآمدی بسیاری از روش‌های تشخیص حملات) ، از هدررفت پهنای باند جلوگیری می‌کند و همچنین یکنواختی^۱ را در زمانهای پیک به دلیل ماهیت

¹ consistency

توزیع شده آن (PE, CE) را دارا می باشد. همچنین از اطلاعات به دست آمده توسط موتورهای تشخیص مستقر در قسمت فراهم کننده و ارسال اطلاعات موردنظر آنها از سمت مشتری، ISP ها می توانند دستگاه های بات نت مستقر در قسمت مشتری ها و ترافیک آنها را شناسایی کنند و از پردازش مجدد این ترافیک ها جلوگیری کنند. این روش در مقابله با حملات اسپم نیز می تواند مفید واقع شود. در این روش دو شبکه یادگیری عمیق استفاده و بررسی شده است.

در نتیجه ارزیابی نیز مشاهده می کنیم که می تواند ۹۰ درصد ترافیک را در مبدا (لبه مشتری) و ۹۷ درصد از حجم باقی مانده را در سمت فراهم کننده شناسایی و کنترل نماید.



مدل و معماری: از یادگیری عمیق برای

شناسایی حملات به دلیل مصرف کم تر حافظه نسبت به روش های دیگر یادگیری ماشین و همچنین دقت بالاتر استفاده می کنیم. دستگاه های مبدا با استفاده از SDN مدیریت می شوند. بروی دو بخش لبه مشتری (CE) و لبه فراهم کننده (PE) اجرا می شود. اجزای اصلی این دو بخش به ترتیب Customer Edge Router و Provider Edge Router که روترهای برنامه پذیر و مدل پیشرفته تر مودم های کابلی هستند.

CER ها یک کامپوننت C-Defense دارند که از یک شبکه عصبی عمیق برای شناسایی استفاده می کند و مدام توسط ISP آموزش داده می شود. PER ها به CER متصل بوده و ترافیک از این طریق عبور خواهد کرد. در CE یک ماژول تشخیص حمله سبک برای پیش اسکن ترافیک مهاجم اجرا می شود تا از بار روی PE بکاهد. CER از دو بخش تشکیل شده است: تشخیص (الگوریتم یادگیری ماشین که یک احتمالی برای ترافیک می دهد) و مقابله^۲: در اینجا مقدار آستانه تعریف شده (برای هر CE می تواند متغیر باشد و توسط ISP تعیین می شود) تعیین می کند که ترافیک در همان منبع دور ریخته شود یا به لایه های بالایی برود. P-Defense که در PE هست ترافیک های جمع آوری شده توسط کامپوننت C-Defense را بیشتر می تواند بررسی کند (بر اساس احتمال به دست آمده). از سه بخش تشکیل شده است: ماژول ارزیابی: بر اساس دو مقدار آستانه برای ترافیک ورودی از CE خروجی از ISP تصمیم می گیرد. اگر ترافیک ورودی از مقدار آستانه پایین تر بود به ماژول بعدی P-Detector می رود که در آنجا ترافیک های ارسالی از منابع متفاوت را به هم وصل می کند و بر اساس آن برای شناسایی تصمیم می گیرد و سپس برای مقابله به بخش mitigation می فرستد.

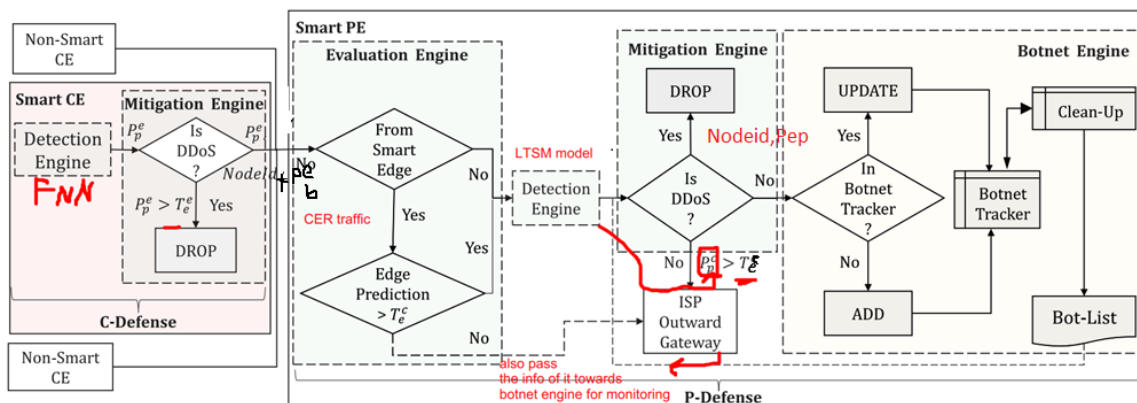
مدل مهاجم: فرض می کنیم CER و PER دیوایسهای کاملاً محافظت شده باشند. P-defense به خاطر botnet engine ای

که دارد می تواند از مورد قربانی قرار گرفتن خودش جلوگیری نماید.

² mitigate

دیتاست مورد استفاده CICDOS2019 می باشد که شامل حملات حجیم (روی ۱۲ تا پروتکل مختلف باشد) و متداول منع خدمت امروزی باشد. از برخی برای یاددهی و بقیه برای آزمایش استفاده می کنیم.

جزئیات:



Algorithm 1 C-Defense Implementation Algorithm

```

1: Input: Outgoing Traffic(R)
2: Output: Action To Take(A)
3: procedure AT-THE-SOURCE(R)
4:    $F \leftarrow \text{Extract-Features}(R)$   $src\ ip, dst\ ip, protocol, packet\ inter-arrival\ time,$ 
5:    $P_p^e \leftarrow \text{DETECTION-ENGINE}(\text{Model}, F)$  threshold
6:   if  $\text{MITIGATION-ENGINE}(P_p^e, T_p^e)$  is FORWARD then
7:     FORWARD tuple(R, NodeId,  $P_p^e$ )
8:   else
9:     DROP R
10:  end if
11: end procedure

```

I. C-Defense : مدل FNN (مبتنی بر DNN) توسط

یک دیتاست از انواع مختلف حملات منع خدمت برچسب گذاری شده، توسط ISP مرتباً آموزش داده می شود.

II. P-Defense : مدل LSTM نیز توسط ترافیک های

حمله برچسب گذاری شده، آموزش داده شده است.

III. Botnet engine : یک جدول ترافیک دارد که شامل

NodeID, DestIP, SrcIP, DestPort, SrcPort, FwdPacket (number of forwarded packets), BwdPackets (number of backward packets), P_b^c هر entry بعد از یک مدت t پلک خواهد شد. هنگام حذف یک entry اگر FwdPckt از MinFwdPkts باشد، NodeId مربوطه به لیست مشکوک ها اضافه می شود و وقوع های دوباره آن شمارش می شود. اگر تعداد دفعات حاضر شدن آن nodeId بیش از مقدار تعیین شده توسط ISP باشد، به لیست سیاه اضافه می شود و به این روش تشخیص بر مبنای رفتار پایه ای یک سیستم بات هست که در آن درخواستی فرستاده شود، اما فرستنده تمایلی آن درخواست را ادامه نمی دهد. که در نتیجه تعداد بسته های سشن کمتر از مقدار آستانه تعیین شده خواهد بود.

به دلایل زیر دولا به تشخیص باید داشته باشیم:

- ترافیک های ناهمگون (همشون از CE ها نمی آیند) که به ISP PE وارد می شوند.

- ترافیک های وابسته به زمان-مکان : با استفاده از LSTM می توان آنها را کنترل کرد
- یکنواختی : مقداری از کار را به روی لبه مشتری تقسیم می کنیم

ارزیابی کارایی: دیتاست را نرمال سازی کرده و همچنین ویژگی^۳های بی اهمیت و رکوردهای تکراری را حذف کرده ایم. با دو مدل ترافیک تست کرده ایم، مدل اول که برخی از CE ها ترافیک بات دارند و در مدل دوم همه CE ها دیوایس بات دارند. اینکه چرا از مدل های موجود، دو مدل LSTM و FNN انتخاب شده است، در مقاله ذکر شده است. سپس دقت این دو مدل را در تشخیص انواع حملات مقایسه کرده است. از آزمایش ها نتیجه می گیرد که شبکه های عصبی ساده مثل FNN به تنهایی برای شناسایی حملات توزیع شده کافی نیستند و مدل های مبتنی بر time-series می توانند موثر واقع شوند.

³ feature